

FinFusion:

A Precise SEC 10-K QA System Powered by RAG + LLM

LLM Disclosure Bureau 06106

Form 10-K

☒ ANNUAL PROJECT REPORT PURSUANT TO SECTION 1.0 OF THE AI RESEARCH & DEVELOPMENT ACT OF 2025

For the research cycle in progress as of May 2025

or

☐ TRANSITION REPORT PURSUANT TO SECTION 1.0 OF THE AI RESEARCH & DEVELOPMENT ACT OF 2025

For the transition period from (project still under development)

Project registration number: FINFUSION-2025

Suyeon Cha

Project ID	FIN-LLM-2025
Duration	April 2025 – May 2025
Key Technologies	Python, LangChain, HuggingFace, FAISS, BM25, ChatOllama
Github	https://github.com/cha-suyeon/Finfusion.git

1.**Project Overview****2.****System Design and Implementation****3.****Experiment and Result****4.****Future Improvement**

FinFusion

A Precise SEC 10-K QA System Powered by RAG + LLM

1. 문제 정의

- 투자자는 기업의 재무 상태와 리스크 정보 파악 위해 정확하고 신뢰할 수 있는 정보 출처가 필요함
- SEC 10-K 보고서는 미국 상장기업이 공시하는 가장 공식적인 연간 재무 보고서
- 하지만 보고서는 수백 페이지 분량으로 구성되어 있어, 일반 투자자에게는 이해와 접근이 어려움
- 자연어 질문에 바로 답할 수 있는 질의 응답 시스템이 부재함
- 특히 수치 기반 정보는 오독·오해의 위험이 높음

1168-115%+

UNITED STATES
SECURITIES AND EXCHANGE COMMISSION
Washington, D.C. 20549

FORM 10-K

☒ ANNUAL REPORT PURSUANT TO SECTION 13 OR 15(d) OF THE SECURITIES EXCHANGE ACT OF 1934
For the Fiscal Year Ended June 30, 2024

OR

☐ TRANSITION REPORT PURSUANT TO SECTION 13 OR 15(d) OF THE SECURITIES EXCHANGE ACT OF 1934
For the Transition Period From to Commission File Number 001-37845

MICROSOFT CORPORATION

WASHINGTON
(STATE OF INCORPORATION)

ONE MICROSOFT WAY, REDMOND, WASHINGTON 98052-6399
(425) 882-8080
www.microsoft.com/investor

91-1144442
(I.R.S. ID)

Securities registered pursuant to Section 12(b) of the Act:

Title of each class	Trading Symbol	Name of exchange on which registered
Common stock, \$0.00000625 par value per share	MSFT	NASDAQ
3.125% Notes due 2028	MSFT	NASDAQ
2.625% Notes due 2033	MSFT	NASDAQ

Securities registered pursuant to Section 12(g) of the Act:

Source: Microsoft 10-K Filing (2024), SEC EDGAR

FinFusion

A Precise SEC 10-K QA System Powered by RAG + LLM

2. 프로젝트 목표

- 투자자의 자연어 질문에 정확하게 응답하는 LLM 기반 QA 시스템 구축 
- SEC 10-K 보고서에서 필요한 정보를 정확히 추출 
- 정량적 수치와 정성적 설명을 포함한 신뢰할 수 있는 응답 생성 
- Hallucination을 최소화한 근거 기반 응답 구조 설계 

FinFusion Pipeline

LLM 기반 질의응답 시스템을 위한 전체 처리 흐름

SEC 10-K 보고서로부터 정량·정성 정보를 추출 후, 정확한 응답을 생성하는 일련의 과정 포함

수집 → 파싱 → 분할 → 임베딩 → 검색 → 재정렬 → 응답




Figure. FinFusion Pipeline Overview

SEC Report Collection

- 기술/도구: [sec-edgar-downloader]
- 역할: 미국 SEC 공시 사이트에서 10-K 보고서를 자동으로 수집
- 형식: HTML 구조를 포함한 .txt 파일로 저장
- 필터링: CIK와 연도 정보를 기준으로 최신 10-K 보고서를 n개 선택

```
1 0000320193-23-000106.txt : 20231103
2 0000320193-23-000106.hdr.sgml : 20231103
3 20231102180827
4 ACCESSION NUMBER: 0000320193-23-000106
5 CONFORMED SUBMISSION TYPE: 10-K
6 PUBLIC DOCUMENT COUNT: 96
7 CONFORMED PERIOD OF REPORT: 20230930 회계 연도
8 FILED AS OF DATE: 20231103
9 DATE AS OF CHANGE: 20231102
10
11 FILER:
12
13 COMPANY DATA:
14 COMPANY CONFORMED NAME: Apple Inc.
15 CENTRAL INDEX KEY: 0000320193 기업 고유 식별 번호 (CIK)
16 STANDARD INDUSTRIAL CLASSIFICATION: ELECTRONIC COMPUTERS [3571]
17 IRS NUMBER: 942404110
18 STATE OF INCORPORATION: CA
19 FISCAL YEAR END: 0930
20
21 FILING VALUES:
22 FORM TYPE: 10-K 보고서 확인
23 SEC ACT: 1934 Act
24 SEC FILE NUMBER: 001-36743
25 FILM NUMBER: 231373899
```

Figure. Raw Header Preview from a Downloaded 10-K Filing

HTML Parsing and Section Extraction

```
1  ==== AAPL (2024) ====  
2  
3  Item 2.    Properties  
4  The Company's headquarters is located in Cupertino, California.  
5  As of September 28, 2024, the Company owned or leased facilities and land for  
6  corporate functions, R&D, data centers, retail and other purposes at locations  
7  throughout the U.S. and in various places outside the U.S.  
8  The Company believes its existing facilities and equipment, which are used by  
9  all reportable segments, are in good operating condition and are suitable for  
10 the conduct of its business.  
11 Item 3.    Legal Proceedings
```

Figure. Preprocessed 10-K Text from Item 2 "Properties"

기술/도구: BeautifulSoup, HTML, re

역할:

- 대상 블록 선별: SEC 10-K 보고서 내 <TEXT> 블록 중 <TYPE>10-K와 <html> 태그가 포함된 본문만 추출
- HTML 태그 제거: BeautifulSoup과 정규 표현식을 활용해 HTML 태그를 완전히 제거, 사람이 읽기 쉬운 평문 텍스트로 변환
- 데이터 정제: XBRL 등 기계 판독용 문서는 제외하여 텍스트의 불필요한 오염 방지
- 후속 처리 준비: 변환된 텍스트는 청킹(chunking)과 섹션 매핑을 통해 RAG 시스템에 최적화된 구조로 가공"

Document Chunking

기술/도구:

- LangChain, re

역할:

- SEC 보고서를 Item 단위로 정규표현식으로 구조화
- 각 Item 내부 텍스트를 의미 단절 없이 청크로 분할
- 청크마다 metadata를 부착해 후속 임베딩/검색에서 문맥 정확도 및 재현성 향상

```
1 metadata={
2   "ticker": ticker,
3   "company_name": company_name,
4   "fiscal_year": year,
5   "filing_year": filing_year,
6   "conformed_period_of_report": conformed_period,
7   "year": year,
8   "part": section["part"],
9   "item": section["item"],
10  "item_title": section["title"],
11  "chunk_id": i,
12  "contains_table": contains_table
13 }
```

Figure. Chunk Metadata Schema

Embedding Creation

기술/도구:

- HuggingFaceEmbeddings (intfloat/e5-base-v2), LangChain, FAISS

역할:

- 청크된 문서를 의미 기반 벡터로 변환
- 유사 문장 검색을 위한 FAISS 인덱스 생성 및 저장




Figure: Embedding & Indexing Workflow

Hybrid Retrieval (BM25 + FAISS)

기술/도구:

- BM25 (rank_bm25), FAISS, RRF (Reciprocal Rank Fusion), LangChain, Ollama

역할:

- 키워드 기반(BM25)과 의미 기반(FAISS) 검색을 함께 사용해 질의와의 다각적 유사성 평가
- 각 Top-K 결과를 Reciprocal Rank Fusion(RRF) 방식으로 통합
- 통합된 후보를 LLM 기반 Re-ranking으로 의미 적합도를 다시 평가
- 최종적으로 가장 적합한 문서를 추출하는 복합 검색 구조 구현




Figure: Hybrid Retrieval Workflow

Semantic Section Filtering

기술/도구:

- HuggingFaceEmbeddings, Cosine Similarity

역할:

- 투자자의 자연어 질문을 SEC 보고서 항목(Item 1~16)에 semantic similarity 기반으로 자동 매핑
- 각 Item 설명과 질문 간 유사도를 계산해 Top-K 관련 섹션만 선택
- Section-level semantic filtering을 적용하여 불필요한 문서를 사전에 제거하고 핵심 근거 영역만 집중 탐색
- 이 방식은 최근 RAG 및 QA 시스템에서 사용되는 semantic decomposition 및 selective context filtering 전략에서 영감 받음





Figure: Semantic Mapping of Natural Questions to SEC Items

Context-Aware Answer Templates



```
1 Query: "What were the total revenue and net income for the latest fiscal year?"
2
3 Answer Instruction
4 1. Begin by locating the financial statements section in the company's latest 10-K filing.
5   - In this case, the company is Apple Inc., and we are looking at their filings from 2023. The financial statements section can be found starting on page 89.
6 2. Search for the "Income Statement" or "Statement of Operations" within the financial statements section.
7   - The Income Statement can be found on page 89, under the caption "Statement of Operations."
8 3. Locate the information on total revenue and net income for the latest fiscal year (2023).
9   - Total net sales were $383.3 billion during 2023, as stated in the Income Statement.
10  - Net income was $97.0 billion during 2023, also stated in the Income Statement.
```

Figure: LLM-Generated Step-by-Step Answer Template

기술/도구:

- LangChain, Ollama, Prompt Engineering

역할:

- 질문 유형과 의도에 따라 LLM 응답 포맷을 동적으로 생성
- SEC 보고서 기반 응답에 맞는 3단계 reasoning template 유도
- 수치 기반 질의, 추론 질의 등 다양한 유형에 맞춰 context-aware instruction을 설계
- Hallucination 방지 및 답변 일관성 확보에 기여

Experiment Detail

실험 목적

- SEC 10-K 기반 RAG QA 시스템이 실제 투자자 질문에 대해 정확하고 근거 기반의 신뢰 가능한 응답을 생성할 수 있는지 검증

테스트 방식

- 기업: Airbnb(ABNB), Costco(Cost), NKE(NIKE), Uber(UBER), Visa(V)
- 각 연도별 SEC 10-K 보고서 사용

질문 유형별 테스트:

- 재무 수치 질의 (e.g., 매출, 순이익)
- 리스크 요인 질의 (e.g., Item 1A)
- 경영 전략 질의 (Item 7)

Representative Questions for SEC 10-K Analysis


- 
1. What is the company's primary business model and revenue drivers?
 2. What were the total revenue and net income for the latest fiscal year?
 3. What was the year-over-year revenue growth?
 4. What are the top three risk factors disclosed in the report?
 5. What lawsuits or regulatory actions were disclosed in Item 3 or Item 8, and what is their estimated financial impact?
 6. How did each operating segment perform (revenue, margins)?
 7. How have operating cash flow (OCF) and free cash flow (FCF) trended?
 8. Did the company repurchase shares or issue dividends this year?
 9. Which macroeconomic risks (e.g., inflation, tariffs) are highlighted?
 10. What strategic priorities did management emphasize for the next year?

Figure: Representative Query Set Template

SEC 10-K 보고서를 참고할 때, 일반 투자자들이 실제로 묻는 **핵심 질문들**을 정리한 리스트

Result 1 – STARBUCKS



Did the company repurchase shares or issue dividends this year?

In 2023, STARBUCKS repurchased shares and issued dividends.
During the fiscal year ended October 1, 2023, the company repurchased **10.0 million shares** of common stock for **\$1.0 billion** on the open market.
As of October 1, 2023, **42.6 million shares** remained available for repurchase under current authorizations.
During the fourth quarter of fiscal 2023, STARBUCKS's Board declared a **cash dividend of \$0.57 per share**, to be paid on **November 24, 2023**, to shareholders of record as of the close of business on **November 10, 2023**.
The expected payout was approximately **\$651.2 million**.
No information about any changes in the dividend policy during the year was found.



- 2023년 기준 자사주 매입(1.0B 달러)과 배당(0.57달러/주, 총 651.2M 달러 지급 예정) 모두 명확히 언급
- 시점, 금액, 지급일, 기준일까지 포함되어 정보 누락 없이 완전
- 정확한 수치 기반의 응답으로 정확성, 정보 완결성, 사실성/객관성이 잘 보장된 사례

Result 2 – Airbnb



What strategic priorities did management emphasize for the next year?

In 2023, ABNB emphasized the following strategic priorities:

- Maintaining and strengthening their brand as a key factor in attracting and retaining Hosts and guests.
- Investing in online and offline marketing distribution channels for brand marketing efforts.
- Reducing performance marketing efforts.



In 2024, ABNB emphasized the following strategic priorities:

- Prioritizing the long-term interests of the company and its stakeholders.
- Enhancing platform trust and safety.
- Improving community support.
- Investing in relationships.
- Adapting to evolving regulations.

- 전략 목표를 구체적 항목별로 명확히 제시, 기업 특성(플랫폼·커뮤니티 중심) 반영하였음
- 2024년 전략 항목들을 빠짐없이 포함하며, 전체적으로 핵심 전략 방향성을 모두 포괄하고 있음
- 실제 10-K 보고서 기반 표현만 사용되었고, 미래 전략에 대해 과장이나 추정 없이 서술되어 사실성이 높음

Result 3 – VISA



What are the top three risk factors disclosed in the report?

The top three risk factors disclosed in the report are not explicitly stated for both years.

- **In 2023**, under Regulatory Risks, the following are mentioned as risks: **Anti-Corruption, Anti-Money Laundering, Anti-Terrorism, and Sanctions.**
- **In 2024**, the top three risk factors are not directly listed but include: **Economic conditions, changes in customer preferences or competition, and regulatory developments.**



- 리스크를 연도별, 주제별로 나누어 명확히 정리하고 있음
- 번호와 소제목 구조가 잘 갖춰져 있어 읽기 쉬움
- 프롬프트 지침에 따라 명시된 항목만 제시하고, 순위화되지 않은 리스크는 명확히 구분하여 설명함

Qualitative Evaluation Criteria

평가 항목	성과 요약
1. 정확성 (Accuracy)	10-K 내 명시된 수치와 문구를 충실히 인용 - 프롬프트의 "명시적 수치만 사용" 지침을 잘 준수 - 연도별, 출처별(예: "2025년 Item 8 - Financial Statements")로 명확히 표기
2. 프롬프트 준수 (Prompt Adherence)	- 템플릿 기반 reasoning, 단계별 접근(예: 1. 비즈니스 설명, 2. 수익원 분석 등) 충실 준수 "추정 금지", "없으면 없다고 답변" 등 규칙 엄격히 지킴
3. 정보 완결성 (Completeness)	- 질문 범위 내에서 보고서에 명시된 모든 관련 정보를 빠짐없이 제공 - 연도별 비교, 수치 변화 등도 명확히 언급
4. 사실성 / 객관성 (Factuality)	- 주관적 해석 없이, 보고서 근거에 기반한 사실만 제시 "추정 금지" 등 지침 철저히 준수
5. 형식 / 가독성 (Formatting)	- 단계별, 항목별로 명확히 구분하여 답변(번호, 소제목 등) - 연도, 출처 등 메타 정보 명확 표기

Limitations

1. 정량적 품질 평가의 한계

- 정량 평가 지표를 위한 정답 세트(Golden Set)의 부재
- 실제 투자자의 피드백을 통해 응답의 유용성, 신뢰성, 근거 적합성 평가

2. 복합 질문 대응 한계

- 수치 + 추론이 혼합된 질문에서 LLM의 Hallucination(환각)이 발생
- 특히, 추론 기반 질문에서 잘못된 전제로 없는 숫자를 생성하는 경향
- 복잡한 해석은 후속 질의로 분리하는 전략이 효과적

3. 표 정보 처리 한계

- 숫자가 많은 청크에서 정확한 수치 추출 실패 사례 존재
- “표는 계산해야 한다”는 자동화된 오해 패턴 발생

System Improvements

1. 질문별 Answer Template 동적 생성
 - LLM이 질문 유형별로 적합한 응답 구조를 스스로 생성
 - 프롬프트 오류, 오독 감소
 2. 챗봇형 연속 질의 응답 구조
 - 대화 기반 탐색(Conversational Exploration) 지원
 - 후속 질문을 통한 정보 보완 및 문맥 이해 강화
 3. Item-level 매핑 정확도 및 Table-aware 정렬
 - 숫자 포함 chunk 우선 검색하여 수치 질의 정확도 향상
-

Future Directions

1. Table-Aware Retrieval 고도화
 - 표 정보가 포함된 청크를 별도 분류/추출
 - 수치 질의의 정밀도 및 근거 제시력 강화
 2. Answer Template Few-shot Learning 또는 Fine-tuning
 - 다양한 질문 유형에 구조화된 응답 생성 학습
 - 복잡한 질문에서도 일관된 reasoning 구조 제공
 3. Multi-turn Chat + Retrieval Memory 고도화
 - 메모리 기반 topic-aware refinement로 확장
 - 사용자의 추론 과정을 누적, context-aware 답변 강화
-

Reference

1. **Yao et al., 2022.**
ReAct: Synergizing Reasoning and Acting in Language Models, <https://arxiv.org/abs/2210.03629>
 2. **Jiang et al., 2023.**
Prompt-as-Program: Interpreting and Executing Programs from Language Instructions, <https://arxiv.org/abs/2305.10855>
 3. **Yao et al., 2023.**
Tree of Thoughts: Deliberate Problem Solving with Large Language Models, <https://arxiv.org/abs/2305.10601>
 4. **Aggarwal et al., 2024.**
ChunkRAG: A Chunk-Level Filtering Method for Reliable Retrieval-Augmented Generation, <https://arxiv.org/abs/2410.19572>
 5. **Villardar, 2025.**
Semantic Decomposition and Selective Context Filtering for LLM-based QA, <https://arxiv.org/abs/2502.14048>
 6. **Cormack et al., 2009.**
Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods, <https://dl.acm.org/doi/10.1145/1571941.1572114>
 7. **Pillai et al., 2023.**
Hybrid Question Answering System: A FAISS and BM25 Approach, <https://arxiv.org/abs/2308.07733>
 8. **Lewis et al., 2020.**
Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks (RAG), <https://arxiv.org/abs/2005.11401>
 9. **Izacard & Grave, 2020.**
Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering (FiD), <https://arxiv.org/abs/2007.01282>
 10. **Longpre et al., 2023.**
The Flipped QA Paradigm for Answering Complex Questions, <https://arxiv.org/abs/2305.13792>
-

THANKS!

Presented by Suyeon Cha
Mail: suyeon.chaa@gmail.com
